

VectorNet论文阅读

#论文介绍

论文核心内容

详解

Vector映射

polyline子图构建

全局图构建

辅助graph completion task

训练

#论文介绍

论文核心内容

该论文的核心内容是将hdmap中的地图表示以及agents的轨迹表示为一个个相连的向量(vector)，然后将这些vector使用MLP的方式以及集成global graph的形式，最后调用基于self_attention的GNN网络训练输出多层的全局特征，然后使用MLP的方式将其解码为特征vector，最后将vector再次转换为轨迹的形式。

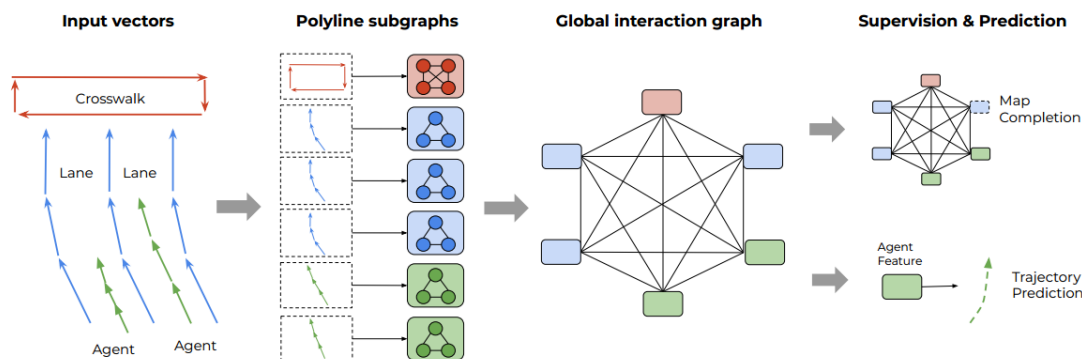


Figure 2. An overview of our proposed VectorNet. Observed agent trajectories and map features are represented as sequence of vectors, and passed to a local graph network to obtain polyline-level features. Such features are then passed to a fully-connected graph to model the higher-order interactions. We compute two types of losses: predicting future trajectories from the node features corresponding to the moving agents and predicting the node features when their features are masked out.

详解

Vector映射

VectorNet将数据主要分为两种，一种是地图数据，一种是agent数据，两种的特征表达方式不太一样

针对地图元素，选择地图元素构成的几何形状，按照空间距离均匀采样key-points，形成vector。

针对agents的轨迹，离散时间向量t，采样控制点，形成vector

主要的形式如下所示：

$$V_i = [d_i^s, d_i^e, a_i, j]$$

式中的 d_i^s 表示该vector的起始点坐标，同样 d_i^e 表示该vector的终止点坐标， a_i 表示的是该vector的特征(向量类型，轨迹时间戳，道路限速等信息)， j 表示的是对应的第j条曲线

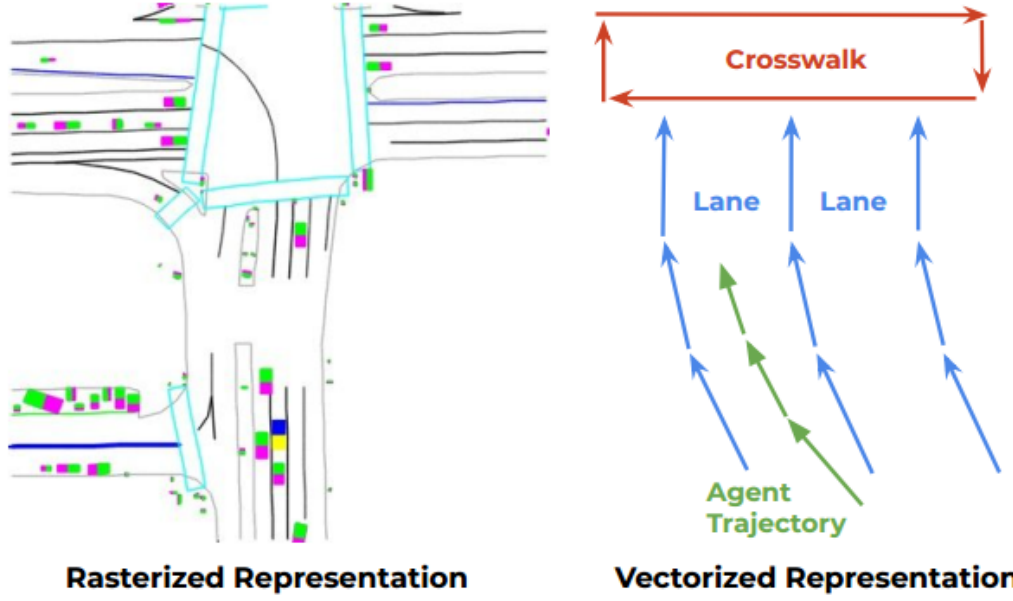


Figure 1. Illustration of the rasterized rendering (left) and vectorized approach (right) to represent high-definition map and agent trajectories.

polyline子图构建

为了充分利用每个子图的空间和语义信息，本论文构建的polyline的每个节点都和每一个节点相连，即全联通图

假设一个polyline P 对应一共有 p 个节点(vector), v_1, v_2, \dots, v_p , 该论文定义单层的子图传播模型如下:

$$v_i^{l+1} = \varphi_{rel}(g_{enc}(v_i^l), \varphi_{agg}(\{g_{enc}(v_j^l)\}))$$

式中 v_i^l 表示第 l 层的节点特征, v_i^0 表示的是该节点特征的输入, 函数 $g_{enc}(\cdot)$ 表示单一节点的特征传递, 函数 $\varphi_{agg}(\cdot)$ 表示集成所有邻居节点的信息, 函数 $\varphi_{rel}(\cdot)$ 表示节点 v_i 和其邻居节点的相关性函数。

论文中实际实现时, 函数 $g_{enc}(\cdot)$ 函数使用的是MLP(权重共享), 这个MLP主要包含三层, 初始输入层->层归一化->ReLU(非线性变化激活函数)层。对polyline的各个节点进行encode编码, 然后将其邻居节点的编码后的特征节点进行一次最大池化(max pooling)操作, 之后采用简单链接(simple concatenation)的方式将本节点编码后的特征向量和其他邻居节点进行链接, 然后形成总的全局节点 P 。流程如下所示:

$$P = \varphi_{agg}(\{v_i^{L_p}\})$$

式中的 φ_{agg} 是一次最大池化操作。

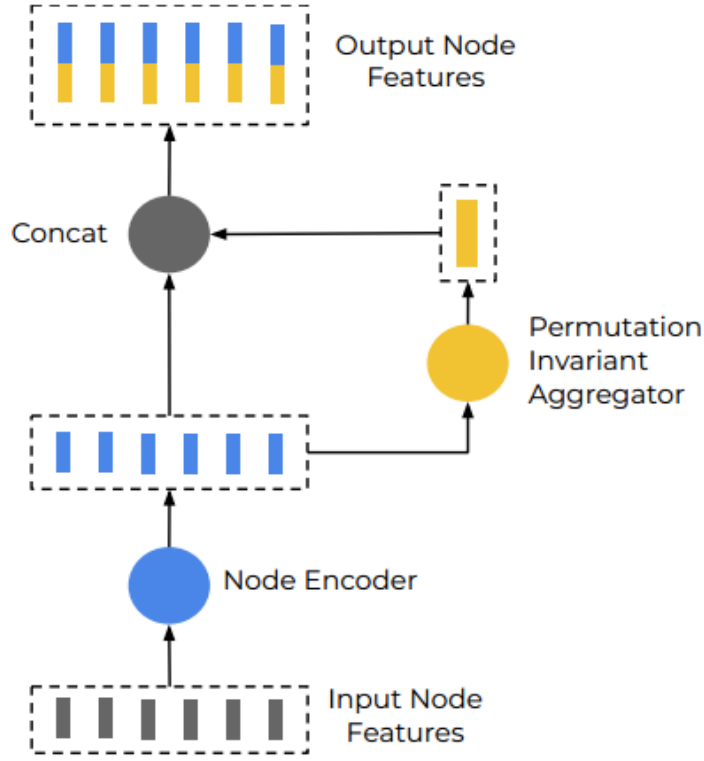


Figure 3. The computation flow on the vector nodes of the same polyline.

全局图构建

在上一步中，论文得到了每条折线对应的全局特征向量 $P = \{p_1, p_2, \dots, p_p\}$ ，定义的全局节点传递模型为

$$\{p_i^{l+1}\} = GNN(\{p_i^l\}, A)$$

论文中假设邻接矩阵 A 是全联通矩阵

论文中使用的图网络模型为自注意力机制，即：

$$GNN(P) = softmax(P_Q P_K^T) P_V$$

最后论文使用MLP对全局特征解码(decoder),反向求解出预测的节点向量，然后生成预测轨迹

$$v_i^{future} = \varphi_{traj}(p_i^{L_t})$$

式中 L_t 表示的是GNN模型的总层数， $\varphi_{traj}(\cdot)$ 表示的是轨迹解码函数

辅助graph completion tash

在训练期间，论文随机遮挡一些斜线节点的特征集合，然后通过MLP的方式降级特征解码

$$\hat{p}_i = \varphi_{node}(p_i^{L_t})$$

然后根据起始坐标点寻找对应的特征，将其作为输入

$$p_i^0 = [p_i; p_i^{id}]$$

训练

经过以

上步骤，论文提出的全局图网络已经构建完毕，此时需要优化训练目标，论文设置的训练目标如下：

$$L = L_{traj} + \alpha L_{node}$$

式中的 L_{traj} 使用的是负高斯对数似然损失函数， L_{node} 表示的是Huber损失函数